

Complements regression logistique

1) Interpretation des coefficients

1.1) Odds = cote = chance : risque

Y = variable binaire $\left\{ \begin{array}{l} 1 = \text{succès, présence, ...} \\ 0 = \text{échec, absence, ...} \end{array} \right.$

$Y \sim \text{Bernoulli}(p) : \left\{ \begin{array}{l} P(Y=1) = p \\ P(Y=0) = 1-p \end{array} \right.$

$\text{cote} = \frac{p}{1-p}$: si un événement (ici $Y=1$) a une faible probabilité, alors il a de grandes chances d'intervenir :

1.2) $\left\{ \begin{array}{l} \text{(rapport de cotes)} \\ \text{Odd-ratio} = \text{mesure de liaison entre une variable binaire } Y \text{ et une variable } X. \end{array} \right.$

$Y=1$ est l'élément d'intérêt. X = variable binaire

Exemple : Y = présence / absence d'une maladie $\Rightarrow \left\{ \begin{array}{l} Y=1 : \text{présence} \\ Y=0 : \text{absence} \end{array} \right.$

X = variable d'exposition à la maladie,

par exemple le sexe : $\left\{ \begin{array}{l} X=1 : \text{Homme} \\ X=0 : \text{Femme} \end{array} \right.$

On définit l'odds-ratio (OR) de Y associé à X par

$$\text{OR} = \frac{p_1 / 1 - p_1}{p_0 / 1 - p_0}$$

où $\left\{ \begin{array}{l} p_1 = P(Y=1 / X=1) \\ p_0 = P(Y=1 / X=0) \end{array} \right.$

Interprétation de l'odds-ratio :

* Si OR proche de 1, le proba d'être malade est identique chez les hommes et chez les femmes
 \Rightarrow le risque de maladie n'est pas associé au sexe.

* Si $OR \neq 1$, il y a une association entre la maladie et le sexe

\Rightarrow Si $OR > 1$, le numérateur est plus grand que le dénominateur donc le risque de maladie est plus grand chez les hommes que chez les femmes

\Rightarrow Si $OR < 1$, c'est le contraire

\Rightarrow l'OR mesure le risque d'1 variable relativement à une autre.

Si X est une variable quantitative

On définit la variable binaire

$$\begin{cases} X = x \\ X = x+1 \end{cases}$$

et on note

$$\begin{cases} p_1 = P(Y=1 / X=x) \\ p_0 = P(Y=1 / X=x+1) \end{cases}$$

On définit alors l'odds ratio de Y associé à X par

$$OR = \frac{p_{11}/1-p_{11}}{p_{01}/1-p_{01}}$$

= mesure de risque que $Y=1$
(maladie par exemple)
lorsque la variable X
augmente d'une unité

Exemple X = âge du patient

- * Si OR proche de 1, le risque de maladie n'est pas associé à l'âge
- * Si $OR > 1$, le risque de maladie est plus grand lorsque l'âge augmente de 1 an
- * Si $OR < 1$, le risque de maladie est plus petit lorsque l'âge augmente de 1 an

1.3) Interprétation des coefficients en régression logistique

Les paramètres $\beta_0, \beta_1, \dots, \beta_p$ du modèle de régression logistique s'interprètent comme des logarithmes d'odds ratio.

1.3.1) Si X^j est binaire

$$e^{\beta_j} = OR = \frac{P_{1/1} \cdot P_1}{P_{0/1} \cdot P_0} \quad \text{où} \quad \begin{cases} P_1 = P(Y=1 / X^j=1) \\ P_0 = P(Y=1 / X^j=0) \end{cases},$$

toutes choses égales par ailleurs (pour les autres variables "fixées")
(TCFPA)

$\Rightarrow e^{\beta_j}$ = odds ratio du risque de survenue de l'événement ($Y=1$) chez les sujets exposés à la variable (facteur) X^j , par rapport aux sujets non exposés, ajusté sur les autres variables explicatives du modèle (TCFPA)

1.3.2) Si X^j est quantitative

$$e^{\beta_j} = OR = \frac{P_{1/1} \cdot P_1}{P_{0/1} \cdot P_0} \quad \text{où} \quad \begin{cases} P_1 = P(Y=1 / X^j=x) \\ P_0 = P(Y=1 / X^j=x+1) \end{cases}$$

toutes choses égales par ailleurs (TCFPA)

$\Rightarrow e^{\beta_j}$ = odds ratio du risque de survenue de l'événement ($Y=1$) pour une augmentation d'une unité de la variable (facteur) X^j , toutes choses égales par ailleurs

2) Log. vraisemblance en régression logistique

$$\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$$

Δ loi conditionnelle Y/X

Echantillon $(X_1, Y_1), \dots, (X_n, Y_n)$

$$x_i = (1, x_{i1}, \dots, x_{ip})^T$$

$$\ell(\beta) = \log \prod_{i=1}^n P(Y_i = y_i / X_i = x_i)$$

Notation :

$$y_i = 1 \Rightarrow \boxed{P(Y_i = 1 / X = x_i) = p_i}$$

$$y_i = 0 \Rightarrow P(Y_i = 0 / X = x_i) = 1 - p_i$$

D'où

$$\ell(\beta) = \log \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1 - y_i}$$

$$= \sum_{i=1}^n \left[y_i \log p_i + (1 - y_i) \log (1 - p_i) \right]$$

$$\text{Or } p_i = \frac{\exp(x_i^T \beta)}{1 + \exp(x_i^T \beta)} = \frac{1}{1 + \exp(-x_i^T \beta)}$$

Donc

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log \left(\frac{1}{1 + \exp(-x_i^T \beta)} \right) + (1 - y_i) \log \left(1 - \frac{1}{1 + \exp(-x_i^T \beta)} \right) \right]$$

$$\frac{\exp(-x_i^T \beta)}{1 + \exp(-x_i^T \beta)}$$

$$= \sum_{i=1}^n \left[\log \left(\frac{\exp(-x_i^T \beta)}{1 + \exp(-x_i^T \beta)} \times \frac{\exp(x_i^T \beta)}{\exp(x_i^T \beta)} \right) \right. \\ \left. + y_i \left(\log \left(\frac{1}{1 + \exp(-x_i^T \beta)} \right) - \log \left(\frac{\exp(-x_i^T \beta)}{1 + \exp(-x_i^T \beta)} \right) \right) \right]$$

$$= \sum_{i=1}^n \left[\log \left(\frac{1}{\exp(\vec{x}_i^T \beta) + 1} \right) + y_i \log \left(\frac{1}{\exp(-\vec{x}_i^T \beta)} \right) \right]$$

$$= \sum_{i=1}^n \left[\overset{0}{\log(1)} - \log(1 + \exp(\vec{x}_i^T \beta)) + y_i \overset{0}{\log(1)} - y_i \log(\exp(-\vec{x}_i^T \beta)) \right]$$

$$= \sum_{i=1}^n \left[-\log(1 + \exp(\vec{x}_i^T \beta)) + y_i \vec{x}_i^T \beta \right]$$